PRML 第一次作业报告：Linear Regression

Wang Linman
buaa_wlm@buaa.edu.cn

Abstract

本报告探讨了线性回归模型在二维数据集Data4Regression上的适用性，并评估了最小二乘法（LS）、梯度下降法（GD）和牛顿法在训练和测试阶段的性能表现。实验结果显示，三种线性拟合方法均未能有效捕捉数据的特征，具体结果如下：

- 最小二乘法拟合曲线为：$y = 0.1089x - 0.6487$，训练和测试的均方误差为0.6134和0.5950。
- 梯度下降法拟合曲线为：$y = 0.1074x - 0.6385$，训练和测试的均方误差为 0.6134 和 0.5946。
- 牛顿法拟合曲线为：$y = 0.1075x - 0.6393$，训练和测试的均方误差为 0.6134 和 0.5946。

可以看出，三种拟合方法的结果较为接近且不能反应数据集的全貌，因此线性模型的拟合效果不理想，对数据集的分布进一步分析后选择非线性模型进行拟合，即加入多项式和非线性项来模拟数据分布，该非线性模型的拟合曲线为：

$$y = 0.0069x^3 - 0.0750x^2 + 0.2659x - 0.6671 - 0.6954\sin(2.4106x - 2.7191)$$

相应的均方误差为 0.3708，显著低于线性模型的误差。这表明多项式和三角函数的组合能够更有效地捕捉数据的非线性特征，验证了模型选择对数据拟合的重要性。本报告最后对结果进行了深入分析，探讨了模型选择的依据及其对数据拟合的影响，为后续研究提供了参考。

Introduction

随着数据科学和机器学习的快速发展，模型选择在数据分析中扮演着至关重要的角色。线性回归作为一种经典的统计方法，因其简单性和可解释性，广泛应用于各种回归问题。然而，许多实际数据集往往表现出非线性的特征，这使得线性模型的拟合效果不尽如人意，为了解决线性模型拟合表现不良的问题，本报告首先评估了线性回归在二维数据集Data4Regression上的表现，并通过对比不同优化算法（最小二乘法、梯度下降法和牛顿法）在训练和测试阶段的表现，并以均方误差（MSE）为指标衡量模型拟合效果，以此探讨线性模型的适用性。

在发现线性模型无法有效拟合数据后，本研究进一步探讨了非线性模型的应用，选择了一个结合多项式和三角函数的非线性模型进行拟合。通过对比非线性模型与线性模型的性能，分析模型选择对数据拟合结果的影响，以期为未来的研究提供指导。

本报告将详细介绍数据集的特征、线性和非线性模型的拟合过程、实验结果以及对这些结果的分析和讨论。通过这些分析，我们希望能够验证在面对复杂数据时，选择合适模型的重要性。

Methodology

本部分会阐述所用回归模型拟合的原理，包括其中具体的实现方法和过程。

M1: Least Squares Method

最小二乘法是一种统计方法，用于通过最小化观察值与模型预测值之间差异的平方和来估计线性回归模型的参数。这种方法因其简单性和有效性在拟合线性关系时被广泛应用。其模型可用如下形式表示：

$$y = \beta_0 + \beta_1 x$$

其中x，y，β_0，β_1分别是自变量、因变量、回归线截距、回归线斜率。

最小二乘法的目标是优化以下这个成本函数，这个函数表示残差的平方和：

$\mathrm{Cos}t = J(\beta_0, \beta_1) = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2$，其中$n$，$y_i$，$\hat{y}_i$分别是观测值的数量，因变量实际值和回归模型预测值。为了找到最佳的β_0和β_1，可以对成本函数分别求导，设置导数为零，并解出相应的方程。在实际应用中，最小二乘法可以通过Python 的 NumPy 和 scikit-learn 库来实现。

M2: Gradient Descent Method

梯度下降法是一种优化算法，通过迭代更新模型参数以最小化损失函数，在机器学习和统计建模中广泛应用。这种方法特别适用于大规模数据集和复杂模型的训练。其目标是最小化损失函数，通常使用均方误差（MSE）作为评估标准，损失函数表示为$J(\beta) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$。模型参数更新的规则是$\beta = \beta - \alpha \nabla J(\beta)$，其中$\alpha$为学习率，决定了每次更新的幅度，$\nabla J(\beta)$是损失函数的梯度。该方法首先随机初始化模型参数，然后计算损失函数的梯度，以确定在参数空间中下降的方向，并根据梯度和学习率更新参数，直至损失函数收敛或达到设定的迭代次数。

M3: Newton's Method

牛顿法是一种用于求解非线性方程和优化问题的迭代算法，以其快速收敛性而著称。该方法通过利用目标函数的一阶导数和二阶导数来逐步逼近函数的根或极值点。在优化中，牛顿法通过迭代更新模型参数，以最小化损失函数。

在执行牛顿法时，首先需要计算目标函数的梯度和海森矩阵（即二阶导数矩阵）。更新公式为：$\beta = \beta - H^{-1}\nabla J(\beta)$，其中 H，$\nabla J(\beta)$ 是海森矩阵和损失函数的梯度。通过这种方式，牛顿法能够在每次迭代中更有效地调整参数，快速接近最优解。之后，检查收敛性，计算新的损失函数值，检查梯度的大小是否小于设定的容忍度，或检查参数变化是否小于容忍度。如果满足收敛条件，则停止迭代；否则重新计算梯度和海森矩阵并用于更新参数。

M4: Nonlinear Optimization

在发现线性模型拟合效果不佳后，我观察数据集合的分布从而选择了一个结合多项式和三角函数的非线性模型进行拟合，多项式次数设置为3次，加入正弦项，其形式如下：

$$y = a_0 + a_1 x + a_2 x^2 + a_3 x^3 + \mathrm{b}_1 \sin(c_1 x)$$

拟合时仍采用最小二乘法进行拟合，定义损失函数为均方误差（MSE），以评估模型预测值与实际观测值之间的差异。

拟合时仍采用最小二乘法进行拟合，定义损失函数为均方误差（MSE），以评估模型预测值与实际观测值之间的差异。

Experimental Studies

Table 1: Linear Regression ($y = ax + b$)

New Table	a	b	MSE(train)	MSE(test)
M1	0.1089	-0.6487	0.6134	0.5950
M2	0.1074	-0.6385	0.6134	0.5946
M3	0.1075	-0.6393	0.6134	0.5946

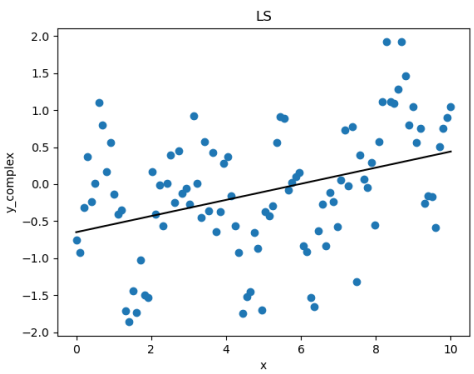

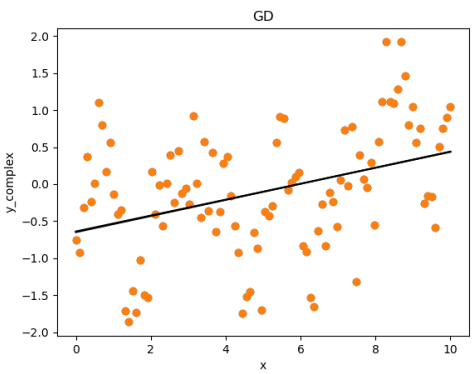

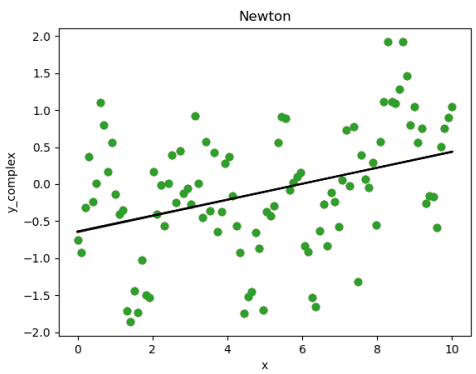

Figure 1：Linear Regression

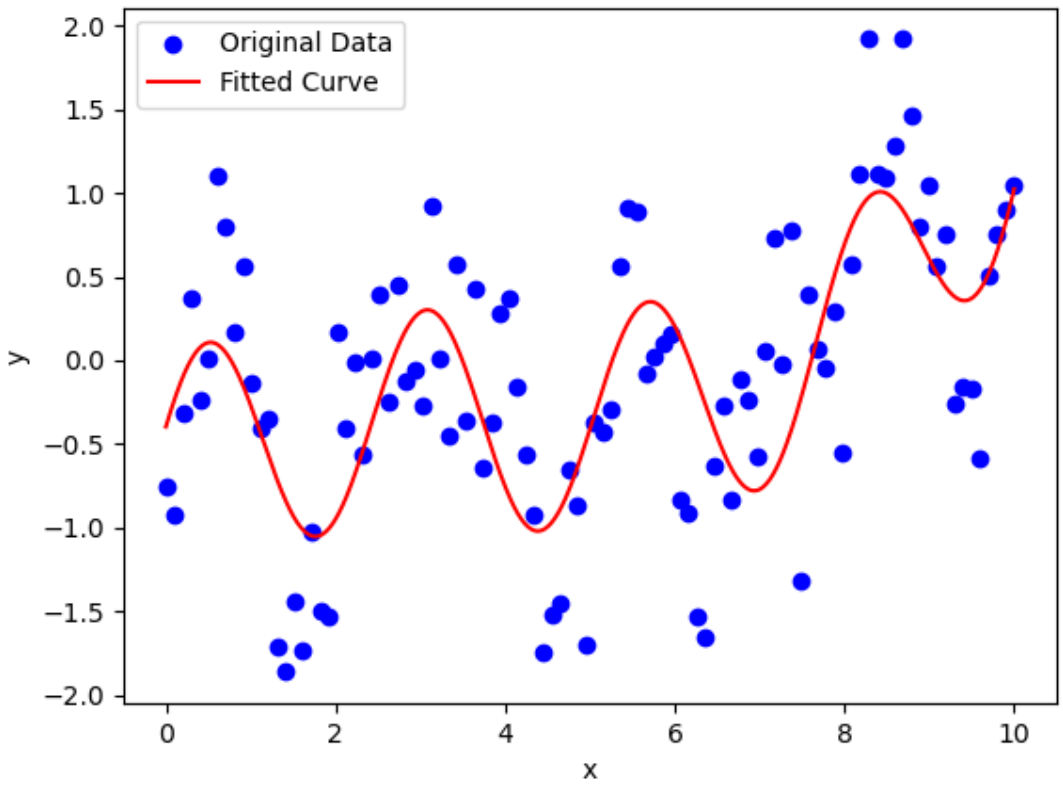

Figure 2：Nonlinear Regression, MSE= 0.3708, thus lower than linear regression

Conclusions

本报告最终发现三种线性回归模型对于数据集的拟合程度较为接近，但以均方误差为指标时，其误差相对于非线性回归模型都较高，大约为1.65倍。因此在数据集本身为非线性的情况下，使用非线性模型拟合的准确程度更高。